

Görüntü-Metin ve Video-Metin Veri Kümelerinin Hizalanması

Alignment of Image-Text and Video-Text Datasets

Yunus Emre Özköse, Zeynep Gökçe, Pınar Duygulu

Bilgisayar Mühendisliği

Hacettepe Üniversitesi

Ankara, Türkiye

{aliozkose, zeynep.gokce}@hacettepe.edu.tr pinar@cs.hacettepe.edu.tr

Özetçe —Bu çalışmada video-metin çiftleri içeren bir veri kümesi ile görüntü-metin içeren bir diğer veri kümesinin hizalanması üzerine çalışılmıştır. Çalışmada önce iki veri kümesindeki metinler üzerinden benzerlikler hesaplanmış, sonrasında bu benzerlikten yararlanılarak oluşturulan alt kümede görsel benzerlik ile bulma-getirme görevi uygulanmıştır. Ham ve saf halleri kullanılan metinlere BERT tabanlı bir gömme vektör metodu uygulanmıştır. Görsel özellikler için nesne tabanlı ve CLIP tabanlı olmak üzere iki farklı yaklaşım kullanılmıştır. Sonuçlara göre ham metin kullanılarak yapılan filtreleme ile oluşturulan alt kümede CLIP özellikleri ile yapılan hizalama sonrasında en iyi sonuçlara ulaşılmıştır.

Anahtar Kelimeler—veri kümesi hizalama, derin öğrenme, makine öğrenmesi

Abstract—In this study, the alignment of video-text and image-text datasets is studied. Firstly, similarities are calculated over the texts in the two data sets. A retrieval setup with visual similarities is then applied to the subset which is created via calculated text similarities. A BERT-based embedding vector method is applied to the raw and pure texts. As a visual feature, object-based and CLIP-based methods are used to define video frames. According to the results, alignment with CLIP features achieves the best results in the subset created by filtering using raw text.

Keywords—dataset alignment, deep learning, machine learning

I. GİRİŞ

İnternet’te hobiden tamire birçok alanda “Kendin yap” (Do It Yourself – DIY) ya da öğretici (instructional) olarak adlandırılan videolar bulunmaktadır. Bu videolarda bir işi gerçekleştirmek için belli bir sırada yapılması gerekenler hem gösterilmekte hem de çoğunlukla sesli olarak anlatılmaktadır. Ancak olayın tamamı uzun zaman alabildiği için çoğu zaman kısa süreli videolar hazırlarken bazı aşamalar atlanmaktadır. Ayrıca aynı olay farklı kişiler tarafından farklı yorumlarla ve sıralarla gerçekleştirilebilmektedir. Çoğu durumda tamamlanması gereken işe dair bir komut dizisi ya da tarif metni de bulunmaktadır. Ama videolar her zaman bütün adımları detaylı olarak göstermemekte ve komut dizisini birebir takip etmeyebilmektedirler. Kendin yap videolarının en çok karşımıza çıkan hali şüphesiz yemek yapma videolarıdır. Bu videoların

yanında birçok web sayfası ve blog bulunmakta, tarif metinleri ve yemek fotoğrafları da paylaşılmaktadır.

Güncel derin öğrenme tabanlı modeller büyük verilere ihtiyaç duymakta ve bu verilerin toplanıp işlenmesi çok büyük emek ve zaman gerekmektedir. Özellikle YouCook2 [1] gibi video-metin veri kümelerinde video gibi karmaşıklığı yüksek bir veri kümesinin etiketlenmesi oldukça zordur. Bu veri kümeleri genelde adım adım eğitimsel metinler ve ilişkilendirilmiş video parçalarını içermektedir, ancak metin ve video eşlemesi birebir değildir. Öte yandan, görüntü-metin çiftlerini içeren veri kümelerinin karmaşıklığı daha azdır. Örneğin RecipeQA [2] veri kümesi tarifler içeren bir veri kümesidir. Her bir tarif eğitimsel adımlar içerir. Bu adımlarda ilgili tarif adımı fotoğrafları da bulunmaktadır.

Bu çalışmada, yemek tariflerine odaklanılarak, birçok kaynaktan toplanan videoların fotoğraf ve metinle eşleştirilmesi, ve farklı kiplerdeki bilgilerin birleştirilerek tümelşik bir öğretici sistemin oluşturulması hedeflenmiştir. Bu sayede, görece daha temiz olan görüntü kümelerinden yararlanılarak bahsi geçen zorluklara çözüm bulunabilmesi ve videoların erişiminin iyileştirilmesi planlanmaktadır.

Bu amaçla, tarifler içeren eğitimsel görüntü-metin veri kümesi ile aynı tip veriler içeren video-metin veri kümesi arasında hizalama yapılmıştır. Önerilen hizalama yöntemi ile iki veri kümesinin metin benzerliği kullanılarak filtreleme yapılmış, oluşan alt kümede ilgili görüntülere benzer videolar görsel özellikler kullanılarak aranmıştır. Sonrasında ise görsel etiketler üzerinden değerlendirilme yapılmıştır. Bu değerlendirmeye video-metin ve görüntü-metin kümelerindeki en benzer örneklerin gerçekten benzer olup olmamaları yönünden doğruluğa katkı sağlamaları ile yapılmıştır.

Literatürde video ve metin hizalaması konusunda çalışmalar bulunmaktadır. Lin ve arkadaşları [3] farklı tarifler arasında önce Hidden Markov Model yöntemi ile video parçaları ve tarif metinleri arasında hizalama yapmışlardır. Bu hizalama sırasında metinlerdeki isimler ve videolardaki nesneler kullanılmıştır. Sonrasında birçok tarifi aynı anda hizalamak için tarif çiftleri için oluşturulan hizalama modelini kullanan bir çizge modeli eğitilmiştir. Donatelli ve arkadaşları [4] ise 10 tane tarif seçerek bu veri üzerinde isim etiketleri yerine aksiyon bilgisi ile tarifler arasında hizalama yapmışlardır. Hizalamada metinlerden ELMO [5] ve BERT [6] gömülü vektörleri çıkartılmış, bu vektörler üzerinde LSTM modeli eğitilmiştir. LSTM modeli

üzerine ise skorlama için ayrı bir çok katmanlı perceptron modeli eğitilmiştir. Dvornik ve arkadaşları [7] iki tarif arasındaki hizalamayı sekanslardaki gereksiz parçaları Dynamic Time Warping (DTW) algoritması ile çıkartarak yapmıştır.

Bahsedilen ilgili çalışmalardan farklı olarak bu çalışmada büyük bir görüntü-metin veri kümesinde ön-eğitim yapılmış CLIP [8] modeli kullanılmış ve ön eğitilmiş BERT modeli ile çıkartılan gömülü vektörler sayesinde hizalama yapılmıştır.

Metin benzerliği ve alt kümede aranan videoların benzerliğine ilişkin detaylar Bölüm II’te anlatılacaktır. Bölüm III ve IV’te ise alınan sonuçlar, analizler ve gelinen sonucu içermektedir.

II. YÖNTEM

A. Metin Benzerliğinin Hesaplanması

İlk olarak, metinler bazı ön işlemlerden geçirilmiştir. Öncelikle yeni satır karakteri gibi gereksiz karakterler temizlenmiştir. Sonrasında cümle içindeki sayılar silinmiştir. Ardından, girdi cümleleri sadece isim ve eylem içerecek şekilde sadeleştirilmiştir. Cümlelerin sadeleştirilmesinde en güncel kütüphanelerden biri olan nltk¹ kütüphanesi kullanılmıştır. Bu kütüphane ile cümlelerde metin parçası etiketleme (post tagging) işlemi yapılmış ve isim ya da eylem olmayan kelimeler cümlelerden atılmıştır. Kütüphane güncel olmasına rağmen emir cümlelerinde yanlış sonuçlar verebilmektedir. Bunu önlemek için cümle başlarına bir şahıs zamiri eklenmiştir. Bu sayede nltk metin parçası etiketleme (post tagging) işleminin başarısı artırılmıştır. Bu işlemlerden sonra filtrelenen etiketler şunlardır: ‘NN’, ‘NNS’, ‘NNP’, ‘NNPS’, ‘VB’, ‘VBD’, ‘VBG’, ‘VBN’, ‘VBP’, ‘VBZ’. Bu işlemlere ek olarak tariflerdeki cümleler birbirinden ayrılmıştır. Güncel cümle sınırı bulma algoritmaları emir cümleleri için başarılı sonuç vermediği için ‘VE’ bağlacına göre de bir cümle sınır ayrımı yapılmıştır. ‘VE’ bağlacından hemen sonra eylem etiketine sahip bir kelime kullanıldıysa cümle ‘VE’ bağlacından ikiye ayrılmıştır. Burada post tagging işleminin emir cümlelerinde iyi sonuç vermesi için ‘VE’ bağlacından sonra bir şahıs zamiri eklenmiş ve sonrasında etiketlemeler yapılmıştır.

Girdi metinleri bahsedilen ön işlemlerden geçirildikten sonra bu metinlerden iki farklı şekilde öznitelik çıkartılmıştır. Birinci yöntemde TF-IDF vektörleri çıkartılırken ikinci yöntemde BERT tabanlı bir gömme çıkarma modeli kullanılmıştır.

TF-IDF yönteminde hesaplama maliyeti ve daha az önemli kelimelerin elenmesi adına boyut sınırlandırılmıştır. Sayım yapılırken kelimeler ve kelime çiftleri kullanılmıştır. Etkisiz kelimeler zaten ön işlemlerde elendiği için vektörleştirmeye dahil edilmemiştir. Girdi metinler küçük harflerden oluştuğu için model harf büyüklüğünden bağımsızdır. Her kelimeye sıfır bölünmeyi önlemek için 1 eklenmiştir. Değerler hesaplandıktan sonra L2 normalizasyon uygulanmıştır.

Kullanılan ikinci öznitelik çıkarma modeli ise ön eğitilmiş Mpnet [9] modelidir. Mpnet modeli BERT temelinde bir model olup BERT modelinden farklı olarak tahmin edilen kelimelerin arasındaki bağlantıyı kaybetmez. Öznitelikler çıkartılırken Sentence Transformers [10] kütüphanesinden yararlanılmıştır.

MPnet modeli cümlelerin ilk 512 karakterini kabul etmektedir ve sadeleştirmenin önemi bu noktada da artmaktadır.

$$v = f_{mpnet}(t) \quad (1)$$

Girdi olarak verilen t cümlesinin sonucunda MPnet modeli 768 boyutlu bir vektör üretir. Bu vektör uzayında RecipQA’daki sorgu cümlesine en benzer YouCook2 adının bulunabilmesi için ise sorgu ile her bir YouCook2 adını arasında kosinüs benzerliği hesaplanmıştır.

$$v_{sorgu} = f_{mpnet}(t_{sorgu}) \quad (2)$$

$$v_{recipeqa} = f_{mpnet}(T_{recipeqa}) \quad (3)$$

$$S = KosinusBenzerlik(v_{sorgu}, v_{recipeqa}) \quad (4)$$

B. Görsel Özniteliklerin Kullanılmasıyla Video-Resim ve Resim-Video Erişimi

Görsel öznitelik çıkarımı için ön eğitilmiş resim tabanlı CLIP [8] ve nesne tabanlı Faster R-CNN [11] derin öğrenme modelleri kullanılmıştır. Bu iki farklı özneliğin kullanılmasıyla görsel benzerlikler analiz edilmiştir. Bu öznitelikler, ön eğitilmiş CLIP ve Faster R-CNN derin öğrenme modellerinin ara katmanlarından elde edilen aktivasyon değerleri kullanılarak çıkartılmıştır.

Faster R-CNN derin öğrenme modeli, görüntüdeki nesnelerin tespiti için kullanılmıştır. RPN (Region Proposal Network) denilen katman ise potansiyel nesnelerin bilgisini içermektedir. Burdan elde edilen farklı boyutlardaki potansiyel nesne bilgisini ortak bir boyuta indirgemek için RoI Pooling katmanı sayesinde havuzlama yaparak sabit boyutlu nesne öznitelikleri elde edilmiştir. Bu potansiyel nesnelerin içinden, en iyi N=20 nesne öznitelikleri kullanılarak, her bir görüntü Nx2048 boyutlu öznitelikler ile ifade edilmiştir. Görüntü öznitelikleri daha sonradan maksimum havuzlama (max pooling) yöntemi ile Nx255 boyutlu özniteliklere indirgenmiştir.

CLIP tamamen resim-metin çiftlerinden oluşan verilerle öğrenme sonucu, verilen bir resime karşılık gelen en benzer metni elde etmeyi amaçlayan bir modeldir. Ön eğitilmiş CLIP derin öğrenme modelinin son ara katmanından elde ettiğimiz 512 boyutlu görsel öznitelikler YouCook2 video kareleri ve RecipeQA resimleri için elde edilmiştir. Sorgu sırasında her bir RecipeQA resmi için en benzer YouCook2 video karesini bulabilmek için sorgu ile her bir YouCook2 video karesi arasında benzerlik hesaplanmıştır.

CLIP tabanlı görsel özniteliklerin kullanılmasıyla, video-resim benzerlik hesaplanması için Kosinüs Benzerlik metodu kullanılmıştır ve Kosinüs Benzerlik metodu aşağıdaki gibi ifade edilmektedir.

$$KosinusBenzerlik = \frac{A \cdot B}{||A|| \cdot ||B||} \quad (5)$$

Yukarıdaki formülde A vektörü YouCook2 video karesine ait özniteligi temsil ederken, B vektörü RecipeQA resmine ait özniteligi temsil eder. Elde edilen yüksek skalar değer, yüksek benzerliği ifade eder, düşük elde edilen skalar değer ise düşük benzerliği ifade eder.

Faster R-CNN modelinden elde edilen nesne tabanlı görsel özniteliklerin kullanılması halinde, Zhou ve arkadaşları [1] tarafından önerilen skor hesaplama yöntemi kullanılmıştır. Her

¹<https://www.nltk.org>

TABLE I: 20 ADET SORU RECIPEQA TARIFINE GÖRE GETİRİLEN YOUCOOK2 TARIFLERİNİN KESİNLİK DEĞERLERİ.

	P@1	P@5	P@10	P@20
tfidf-ham-metin	0.60	0.57	0.48	0.36
tfidf-saf-metin	0.60	0.52	0.45	0.36
bert-ham-metin	0.95	0.76	0.63	0.43
bert-saf-metin	0.90	0.75	0.59	0.39

bir potansiyel nesne öznitelik vektörleri, sorgu görüntüsü için q_k , $k=1,2,3,...,O$ ve veri kümesinde benzerlik hesaplanması istenen diğer görüntü için r_i , $i=1,2,...,N$ şeklinde ifade edilir. Sorgu görüntüsü $Q = (q_1, ..., q_O)$ ve diğer veri kümesindeki görüntü $R = (r_1, ..., r_N)$. Görsel olarak eşleştirme skoru aşağıda gösterilmektedir.

$$S(Q, R) = \frac{1}{O} \sum_{k=1}^O \max(a_k^i) \quad (6)$$

$$a_k^i = q_k^T r_i \quad (7)$$

Burada a_k^i her bir potansiyel nesnenin benzerliğini göstermektedir. Yukarıdaki gibi metinsel ve görsel öznitelikler çıkarılıp benzerlikler hesaplandıktan sonra sorgu kümesi RecipeQA getirme kümesi YouCook2 olacak şekilde bulma-getirme görevi uygulanmıştır. Bu görev metin benzerliği değerlendirmesi için kullanılan alt sette uygulanmış ve metrikler hesaplanırken ilgili doğruluk kümesi olarak manuel etiketlenen metin kümesi kullanılmıştır.

III. DENEYSEL SONUÇLAR VE ANALİZ

A. Veri Kümeleri

a) *YouCookII*: [1] 89 yemek tarifi için YouTube üzerinden toplanan 2000 adet kesilmemiş videodan oluşmaktadır. Bu videolardaki dar hareketler elle belirlenen başlangıç ve bitiş noktaları ile etiketlenerek bölütlenmiş ve o hareketin metinsel açıklaması ilgili kişiler tarafından İngilizce olarak oluşturulmuştur. Bu veri kümesi için ilgili internet sayfasında öznitelikler sağlanmaktadır. Toplamda eğitim ve doğrulama kümelerinde 1790 adet tarif bulunmaktadır. Bu tariflerde kısa ve öz ifadeler bulunmaktadır. YouCook2 veri kümesinin sadece doğrulama kümesi kullanılmıştır. Deneyler esnasında YouCook2 videolardan yalnızca 424 tanesine erişilebilmiştir. Videolar ayrıca bölümlere ayrılmıştır ve her bölüme karşılık gelen metinler bulunmaktadır. Video kareleri 1 fps olacak şekilde ffmpeg kütüphanesi yardımıyla çıkarılmıştır.

b) *RecipeQA*: [2] veri kümesi 22 yemek kategorisi için yaklaşık 20000 yemek tarifi ve bu tariflere dayalı soru cevap çifti içermektedir. Bu soru cevaplar 4 ana başlık altında toplanmaktadır. Bu veri kümesi yemek tariflerinin çok modlu anlaşılması için oluşturulmuştur. Adım adım talimatlar ve ilgili resimler internet üzerindeki kullanıcıların paylaşımlarından toplanmıştır. Her soru başlıklar, açıklamalar veya resimler gibi birden çok modaliteyi kapsar. Tarifler adımların başlığını, adımı anlatan resimleri ve o adımın açıklamasını içerecek şekilde hazırlanmıştır. Veri kümesi eğitim, test ve doğrulama setlerine bölünmüştür. Örnek soru cevaplar ilgili sitede verilmektedir. Bu veri kümesinde anlatımlar daha uzundur ve açıklayıcıdır. Doğrulama kümesi erişilebilir olduğu için deneyler bu set üzerinde gerçekleştirilmiştir. Toplamda 1963 tarif, 11805 tane tarif adımı ve 25010 adet adım resim içermektedir.

TABLE II: NESNE TABANLI YAKLAŞIMIN DUYARLILIK SONUÇLARI

	R@1	R@5	R@10	R@20
tfidf - ham metin	0,36	0,72	4,00	5,45
tfidf - ham metin - filitrelenmiş	0,00	1,09	6,90	10,18
tfidf - saf metin	0,00	0,36	3,27	5,81
tfidf - saf metin - filitrelenmiş	0,00	0,36	4,72	8,72
BERT - ham metin	0,00	1,45	1,45	7,63
BERT - ham metin - filitrelenmiş	0,00	3,27	4,36	12,72
BERT - saf metin	0,36	2,18	2,54	5,81
BERT - saf metin - filitrelenmiş	0,36	3,63	5,81	11,63

TABLE III: CLIP TABANLI YAKLAŞIMIN DUYARLILIK SONUÇLARI

	R@1	R@5	R@10	R@20
tfidf - ham metin	2,18	5,82	9,45	13,09
tfidf - ham metin - filitrelenmiş	2,18	6,55	11,64	18,91
tfidf - saf metin	1,09	4,73	11,64	18,18
tfidf - saf metin - filitrelenmiş	1,09	6,18	15,27	24,36
BERT - ham metin	2,55	6,55	10,55	15,64
BERT - ham metin - filitrelenmiş	2,91	7,27	14,18	24,36
BERT - saf metin	2,55	6,91	9,82	12,73
BERT - saf metin - filitrelenmiş	3,27	8,73	12,73	18,55

B. Metin Benzerliğinin Hesaplanması


Model performansları değerlendirilirken RecipeQA veri kümesinden 20 tane örnek seçilmiş ve bu örnekler sorgu olarak kullanıldığında modellerin getirdiği 20 tane YouCook2 tarifi manuel olarak değerlendirilmiştir. Modellerin ne kadar ilgili tarif getirebildiklerini ölçmek için ise kesinlik değerleri hesaplanmıştır. Tablo I'de 4 model için kesinlik sonuçlarını gösterilmektedir.

Sonuçlara göre BERT tabanlı modeller TF-IDF tabanlı modellere göre daha iyi performans göstermiştir. Bunun nedeni BERT tabanlı modellerin metin içeriğini anlamsal olarak daha iyi kavrayabilmesi olabilir. TF-IDF öznitelikleri sadece kelime frekanslarına baktığı için kelimeler arasındaki bağ bilgisini içermez. TF-IDF öznitelikleri çıkartılırken kelime çiftleri de kullanılmıştır ama bu ilişki çok kısa bir ilişkidir. BERT modeli cümle içerisindeki daha uzun ilişkileri tutabilir. Bu sonuçlar ilgili tariflerin getirilmesinde aslında sadece eylem ve isimlerin tek başına önemli olmadığını, eylem ve isimler arasında kurulan bağların da getirilmesinde yararlı olduğunu göstermektedir. Tarif metinlerini sadeleştirip her iki öznitelik çıkarma yöntemi ile denemek sonuçları iyileştirmemiştir. Bunun sebebi BERT modeli için ön eğitilmiş modelin sadece isim ve eylem girdilerine göre eğitilmemiş olması olabilir.

Sonuçlara göre en yüksek benzerlik oranına sahip tarif sayısı arttıkça kesinlik oranları çok fazla düşmektedir. Bu gözlemden aslında YouCook2 veri kümesinin içerisinde benzer tarif sayısının az olduğunu göstermektedir.

C. Görsel Özniteliklerin Kullanılmasıyla Video-Resim ve Resim-Video Erişimi

Deneylerin görsel olarak analiz edilmesinin yanı sıra metinsel benzerlikler doğru kabul edilerek bu metinler üzerinden doğruluk değerleri elde edilmiştir. Metinsel analizde kullanılan RecipeQA veri kümesinde seçilen 20 örnek ve her bir RecipeQA örneğine benzer 20 adet YouCook2 videosu aynı şekilde kullanılmıştır. Elimizde mevcut olan, metinsel erişim analizi için de kullanılan video tabanlı benzer YouCook2 ve



Şekil 1: Birinci ve ikinci satır metin benzerliği kullanılarak getirilen tarifleri göstermektedir. Üçüncü ve dördüncü satır ise CLIP öznitelikleri kullanılarak görsel benzerlik ile getirilen tarifleri göstermektedir.

RecipeQA listeleri üzerinden görsel erişim doğruluğu hesaplanmıştır.

Buna göre, görsel özniteliklerin kullanılmasıyla, bir RecipeQA sorgu resmine en benzer YouCook video karesi aynı zamanda metinsel olarak da benzer ise bu YouCook2 ve RecipeQA video-resim çifti doğruluk hesabına katkıda bulunmaktadır.

Deneyler, iki farklı öznitelik (CLIP ve Nesne Tabanlı) kullanılarak ilerlemiştir. Bu iki ayrı yaklaşıma ait duyarlılık sonuçları Tablo II ve Tablo III'de verilmiştir. Sonuçlara göre top1 ve top5 durumlarında BERT tabanlı saf metinler ile filtreleme yapıldıktan sonra CLIP tabanlı özniteliklerin kullanılmasıyla bulunan tariflerin en iyi sonuçları verdiği görülmektedir. Top10 ve top20 sonuçlarına bakıldığında 0,1418 ve 0,2436 duyarlılık değerleri ile en iyi sonuçların BERT tabanlı ham metinler ile filtrelemenin verdiği görülmektedir. Metrik tabanlı analizin yanı sıra, görsel olarak YouCook2 ve RecipeQA veri kümelerinden örnekler Şekil 1'de verilmiştir.

IV. SONUÇ

Çalışmamızda video-metin ve görüntü-metin çiftlerinden oluşan veri kümelerini hizalamak amacıyla metinsel ve görsel benzerlik kullanılarak bulma-getirme görevi uygulanmıştır. Metinsel benzerlikler görsel benzerliklere yardımcı olması için filtreleme görevi görmüş ve aramalar oluşturulan alt kümede yapılmıştır. Sonuçlara göre ham metinler ile oluşturulan alt kümede CLIP modeli temelli arama yapmak en iyi sonuçları vermiştir.

TEŞEKKÜR

Bu çalışma 118E283 NO'lu TÜBİTAK projesi kapsamında desteklenmiştir.

KAYNAKLAR

- [1] L. Zhou, C. Xu, and J. Corso, "Towards automatic learning of procedures from web instructional videos," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.
- [2] S. Yagcioglu, A. Erdem, E. Erdem, and N. İkizler-Cinbis, "Recipeqa: A challenge dataset for multimodal comprehension of cooking recipes," *arXiv preprint arXiv:1809.00812*, 2018.
- [3] A. S. Lin, S. Rao, A. Celikyilmaz, E. Nouri, C. Brockett, D. Dey, and B. Dolan, "A recipe for creating multimodal aligned datasets for sequential tasks," *arXiv preprint arXiv:2005.09606*, 2020.
- [4] L. Donatelli, T. Schmidt, D. Biswas, A. Köhn, F. Zhai, and A. Koller, "Aligning actions across recipe graphs," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, 2021, pp. 6930–6942.
- [5] M. E. Peters, M. Neumann, M. Iyyer, M. Gardner, C. Clark, K. Lee, and L. Zettlemoyer, "Deep contextualized word representations," *CoRR*, vol. abs/1802.05365, 2018.
- [6] J. Devlin, M. Chang, K. Lee, and K. Toutanova, "BERT: pre-training of deep bidirectional transformers for language understanding," *CoRR*, vol. abs/1810.04805, 2018.
- [7] M. Dvornik, I. Hadji, K. G. Derpanis, A. Garg, and A. Jepsen, "Drop-dtw: Aligning common signal between sequences while dropping outliers," *Advances in Neural Information Processing Systems*, vol. 34, pp. 13 782–13 793, 2021.
- [8] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark *et al.*, "Learning transferable visual models from natural language supervision," in *International conference on machine learning*. PMLR, 2021, pp. 8748–8763.
- [9] K. Song, X. Tan, T. Qin, J. Lu, and T.-Y. Liu, "Mpnet: Masked and permuted pre-training for language understanding," *arXiv preprint arXiv:2004.09297*, 2020.
- [10] N. Reimers and I. Gurevych, "Sentence-bert: Sentence embeddings using siamese bert-networks," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 11 2019.
- [11] R. Girshick, "Fast r-cnn," in *Proceedings of the IEEE international conference on computer vision*, 2015, pp. 1440–1448.