

Yemek Pişirme Videoları için Otomatik Veri Artırımı Automatic Data Augmentation for Cooking Videos

Yunus Emre Özköse, Pınar Duygulu

Bilgisayar Mühendisliği

Hacettepe Üniversitesi

Ankara, Türkiye

aliozkose@hacettepe.edu.tr pinar@cs.hacettepe.edu.tr

Özetçe —Metin-video çiftleri içeren güncel veri kümeleri ile eğitilen metin-video ortak modelleri genel hareketleri içeren örneklerde güzel sonuçlar vermektedir. Fakat alana özel modeller geliştirilmek istendiğinde veri toplamak ve toplanan verinin etiketlenmesi büyük bir maliyet içermektedir. Bu çalışmamızda yemek pişirme videolarının tanımlanması ve erişimi amacıyla bu konuda oluşturulmuş bir veri kümesi olan YouCook2’yi tamamıyla otomatik olarak genişletmek için bir süreç önerilmiştir. 89 tane tarif kategorisi ile Youtube’da ilgili videolar bulunduktan sonra rastgele örnekleme ile klipler oluşturulmuş ve bir altyazı-lama modeli ile metin-video çiftleri oluşturulmuştur. Genişletilen veri kümesi üzerindeki deneylerimiz otomatik oluşturulan verinin duyarlılık oranlarını artırdığını göstermektedir. Kod ve veriler şu adreste mevcuttur: <https://github.com/EmreOzkose/hucook>

Anahtar Kelimeler—metin-video bul-getir problemi, yemek pişirme videoları, veri kümesi oluşturma, derin öğrenme, makine öğrenmesi


Abstract—Text-video joint models that are trained on state-of-the-art text-video datasets perform well on general text-video datasets that contain general actions. However domain-specific datasets are hard to collect because of data collection and labeling costs. In this work, we propose a pipeline to automatically extend YouCook2 that is collected to define and retrieve cooking videos. Related videos are found with 89 recipe categories, then segments are prepared by random sampling, and segment-text pairs are obtained by a captioning model. Experiments on extended dataset show that automatically created dataset increases recall results. Code and data are made available at <https://github.com/EmreOzkose/hucook>

Keywords—text-video retrieval, cooking videos, dataset creation, deep learning, machine learning

I. GİRİŞ

Farklı kanallardan gelen bilgiyi eş zamanlı işleme konusunda geliştirilen yapay zeka modelleri son yıllarda önem kazanmaya başlamıştır. Metin-video gibi farklı akışlardan gelen bilgi çiftleri oluşturulmakta ve bu çiftler sayesinde ortak modeller eğitilmektedir. Bu sayede metin-video ortak modelleri gibi farklı akışların aynı anda temsil edilmesi ve yorumlanması öğrenilebilmektedir.

Metin-video çiftleri içeren veri kümeleri geçici sınırlar ile belirlenmiş ve bu sınırlar içerisindeki hareketi tanımlayan kelime veya cümle etiketleri olan kliplerden oluşmaktadır. Bu tipte veri kümeleri sayesinde modellerin birçok farklı görevi




Şekil 1: Youtube platformundan toplanan ve tamamıyla otomatik bir şekilde etiketlenen veriler ile YouCook2 veri kümesi artırılmıştır. Sonrasında otomatik bir şekilde artırılan veri ile bir ön-eğitilmiş metin-video ortak model eğitilmiş ve YouCook2 doğrulama kümesi üzerindeki duyarlılık sonuçları iyileştirilmiştir.

öğrenmesi sağlanabilmektedir. İnternetteki ham videolar genelde birden çok hareket içeren uzun videolardır. Bu uzun ham videolardan hareket sınırlarını çıkarmaya geçici sınır belirleme denir ve metin-video kümeleri kullanılarak bu görev için modeller eğitilebilir. Belirli bir hareket içeren kısa kliplerden açıklayıcı metinler çıkartmaya altyazılama görevi [1] denir ve metin-video çiftleri sayesinde klipler için uygun altyazılar çıkartılabilir. Yine aynı tipte veri kümeleri kullanılarak verilen bir metinden video getirme veya verilen bir videodan ilgili metni getirme gibi bul-getir görevleri için modeller eğitilebilmektedir.

Birçok farklı görev için kullanılabilen metin-video veri kümeleri genel içerikli [2] veya alan özel [3] hareketler içerebilmektedir. Alana özel veri kümelerinin oluşturulması metin-video veri kümelerinin içerisindeki kliplerin çıkartılmasının zorluğu nedeniyle çok maliyetlidir. Bu noktada farklı görevlerde kullanılmak üzere metin-video çiftleri içeren bir kümenin otomatik olarak oluşturulabilmesi veriye aç derin öğrenme modellerinin başarılarının artırılmasında büyük önem taşımaktadır.

Bahsedilen görevlerde benzer hareketlere sahip kliplerde iç çeşitlilik fazla olabilmekte veya benzer olmayan hareketlerde ortak hareket metinleri veya görsel benzerlikler içerebilmektedir. Örneğin bir domates kesme klibi farklı zeminlerde farklı renk ve şekillerdeki domateslerin farklı görünüşteki bıçaklar ile kesilmelerini içerebilmektedir. Bununla birlikte bir domatesin kesilmesi, doğranması veya dilimlenmesi birbirine çok benzeyen fakat farklı olan hareketlerdir. Benzer hareketlerin art arda yapılması ise çok daha zorlayıcı bir durumdur. Bütün bu durumları kapsayabilmek ve modelin her duruma gümbüz olmasını sağlamak için verinin büyütülmesi elzemdir.

Çalışmamızda yemek pişirme hareketlerini içeren YouCook2 veri kümesinin kapsayıcılığını ve üzerinde eğitilen



Şekil 2: İndirilen veri (mavi), YouCook2 eğitim (turuncu) ve YouCook2 doğrulama (yeşil) kümeleri için her bir tarif kategorisindeki video sayıları gösterilmiştir. Her bir kategori için Youtube üzerinden ilgili videolar elde edilmiş sonrasında uygun olmayan videolar silinmiştir.

metin-video ortak modelinin gürbüzlüğünü artırmak amacıyla tamamıyla otomatik olarak bir veri genişletme akışı önerilmiştir.

Öncelikle videolar yemek pişirme alanına özel anahtar kelimeler ile Youtube’da aranmış ve indirilmiştir. Sonrasında bu videolardaki geçici sınırlar belirlenmiş ve klipler çıkartılmıştır. Sonrasında çıkarılan klipleri tanımlayan metinler oluşturulmuş ve metin-video çiftleri hazırlanmıştır. Bu süreç genel bir akıştır ve yemek pişirme videoları dışında bir alana da entegre edilebilir. Yemek pişirme hareketlerine özel olarak oluşturulan genişletilmiş bu metin-video veri kümesi sonrasında metin-video ortak model eğitimi için kullanılmıştır. Şekil 1 önerilen yöntemin genel yapısını göstermektedir. Özet olarak çalışmamızın ana katkısı alana özel bir veri kümesinin otomatik olarak genişletişine yönelik bir süreç ve süreç ile elde edilen veri kümesinin herkese açık olarak paylaşılmasıdır.

II. İLGİLİ ÇALIŞMALAR

Eşlenmiş metin-video içeren çeşitli veri kümeleri bulunmaktadır. Sigurdsson ve arkadaşları [4] ev ortamında çekilen Youtube videolarından oluşan ve 9.848 tane video içeren Charades veri kümesini toplamışlardır. Amazon Mechanical Turk (AMT) üzerinden etiketlenen videolarda 157 hareket sınıfı ve 66.500 yerleştirilmiş hareket bulunmaktadır. Miech ve arkadaşları [2] Youtube videolarını içeren ve otomatik etiketleme ile oluşturulmuş metin-video çiftleri içeren HowTo100M veri kümesini tanıtmıştır. Bu veri kümesi 1.22 milyon videodan kesilmiş 136 milyon klip içermektedir. Yazarlar veri kümesini indirdikten sonra metin-video bul-getir görevi dahil 23 farklı görev için eğitimler yapmıştır. Her klip için karşılık gelen metinler ise videoların altyazılarından veya otomatik konuşma tanıma (ASR) ile elde edilmiştir. WebVid-10M [5] zayıf etiketlere sahip 10 milyon videodan oluşan bir metin-video veri kümesidir. Veri kümesi alt yazıları olan Youtube videolarından oluşmaktadır.

Çalışmamızda özel olarak yemek pişirme videoları incelenmiştir. Literatürde yemek pişirme alanında özel olarak oluşturulmuş veri kümeleri de yer almaktadır. Breakfast Hareket [6] kahvaltı hazırlama videolarından oluşan ve 10 tane ilgili hareket içeren bir veri kümesidir. Zhou ve arkadaşları [3] 89 tarif kategorisinden oluşan ve 2000 Youtube videosu

içeren YouCook2 veri kümesini tanıtmışlardır. YouCook2 manuel olarak hazırlanmış hareket sınır etiketlerine sahiptir ve bu hareket klipleri emir cümlelerinden oluşan metinler ile etiketlenmiştir. Damen ve arkadaşları [7], [8] 1. şahıs bakış açısı ile kayıt edilen ve yemek pişirme hareketlerinden oluşan Epic-Kitchens veri kümesini oluşturmuşlardır. Tüm hareket etiketleri AMT üzerinden manuel olarak elde edilmiştir. Veri kümesi toplamda 100 saat olan ve 90.000 hareket içeren 700 videodan oluşmaktadır.

Literatürdeki çalışmalarda yukarıda bahsedilen veri kümeleri kullanılarak metin-video çiftlerinden bul-getir görevi çerçevesinde çok kipli modeller eğitilmiştir. Bu modellerdeki genel yapı video ve metin girdilerinin ayrı modüllerce kodlanması ve elde edilen özniteliklerin farklı yapılarca birleştirilmesi yönündedir. Sun ve arkadaşları [9] videoları kodlamak için S3D [10] modelini kullanıp hiyerarşik k-means ile görsel jetonlar oluşturmuştur. Sonrasında metin jetonları ile beraber bir BERT [11] modeli eğitilmiştir. Miech ve arkadaşları [12] I3D ve S3D modellerini kullanarak video özniteliklerini çıkartmıştır. Metinlerin kodlanması için Word2vec [13] kullanıldıktan sonra iki akış kullanılarak gürültü karşılaştırmalı tahmin (noise-contrastive estimation) ile optimizasyon sağlanmıştır. UniVL [1] modeli metin ve video akışı için ayrı Transformer modeli kullanan ve sonrasında bu akışları birleştirmek ve deşifre etmek için 2 ayrı Transformer modeli daha kullanan bir metin-video ortak modelidir. Modüller arasında ve sonunda kullanılan 4 farklı kayıp fonksiyonu ile modelin farklı görevlerdeki başarısı artırılmak istenmiştir.

Güçlü bir görüntü-metin çoklu modeli olan CLIP [14] modelinin tanıtılması ile beraber video-metin literatüründe CLIP tabanlı modeller inşa edilmeye başlanmıştır. Xu ve arkadaşları [15] ön eğitilmiş video ve metin modellerinden elde ettikleri öznitelikleri çok katmanlı algılayıcılar ile istenilen boyuta yansıtip CLIP modelindeki gibi bir transformer modeli eğitmişlerdir. Literatürdeki diğer benzer modeller görüntü ve metinler arasındaki benzerlikler üzerinden dikkat modelleri eğitime [16], en iyi temsil eden görüntüler ile metinlerin öğrenilmesi [17] ve benzeri yaklaşımlar içermektedir.

TABLO I: VERİ KÜMELERİNİN İSTATİSTİKLERİ

Veri Kümesi	Toplam Süre (Saat)	Klip İstatistikleri	
		Klip Sayısı	Ortalama Süre (Saniye)
YC2-eğitim	105	9215	19
YC2-doğrulama	36	3216	19
HuCook	568	85480	21

III. HUCOOK VERİ KÜMESİ

Çalışmamızda tamamıyla otomatik bir akış ile yemek pişirme videolarının toplanılması amaçlanmıştır. YouCook2 veri kümesi temel alınarak toplanan yeni veri kümesine HUCook adı verilmiştir.

YouCook2 veri kümesi 110 tarif kategorisi içermektedir. Fakat veri kümesini oluşturan araştırmacılar eğitimlerde 89 tanesini kullanmışlardır. Bu 89 tarif kategorisi üzerinden başlarına 'how to make' eklenerek Youtube üzerinde arama yapılmıştır. Örneğin Youcook2'deki 103-burger kategorisi için *how to make burger* şeklinde arama yapılmış ve arama sonuçlarının ilk 5 sayfası dikkate alınmıştır ancak veri kümesinin büyütülmesi için bu sınır artırılabilir. Arama için YoutubeSearchPython¹ kütüphanesi kullanılmıştır. Şekil 2'de YouCook2 ve indirilen veri kümelerinin video sayılarına dair istatistikler verilmiştir. YoutubeSearchPython kütüphanesi Youtube üzerinde arama yapmakta ve sayfalardaki video kimlik bilgisini dönmektedir. Her sayfada eşit video bulunmamaktadır ve videoların bazıları "short" videosu olduğu için veri kümesine dahil edilmemiştir. İndirilen 5046 video yaklaşık 568 saattir ve ortalama video uzunluğu yaklaşık 7 dakikadır.

IV. YÖNTEM

İndirilen videolardan ilgili klipler çıkartıldıktan sonra bir ön-eğitilmiş altyazılama modeli ile klip altyazıları çıkartılmıştır. Böylece bir metin-video modeli için gereken örnek çiftler oluşturulmuştur. Sonrasında YouCook2 üzerinde en güncel sonuçlardan birini veren Videoclip modeli YouCook2 ile beraber yeni veri üzerinde eğitilmiştir. Aşağıda yöntemin detayları verilecektir.

A. YouCook2 Veri Kümesi

YouCook2 [3] Youtube üzerinden elde edilmiş eğitilmiş yemek pişirme videolarından oluşan bir veri kümesidir. Videolar manuel olarak etiketlenmiş klip sınırları ve her bir klip emir kipi kullanılarak hazırlanmış bir İngilizce altyazı içermektedir. Eğitim ve doğrulama kümelerinde toplam 1790 video vardır fakat eğitim kümesindeki 12.2% ve doğrulama kümesindeki 8.6% oranındaki videoya ulaşamamıştır. Klip altyazıları kısa ve öz emir cümlelerinden oluşmaktadır.

B. Kliplerin Oluşturulması

İndirilen videolar sıralı bir şekilde normal dağılımdan gelen rastgele süreler ile kesilmiştir. YouCook2 veri kümesindeki ortalama klip uzunluğu 19 saniye olduğu için klip süreleri 2 ve 40 saniye arasında sınırlandırılmıştır. YouCook2 kliplerindeki süre dağılımı tekdüze dağılımdansa normal dağılıma daha çok benzediği için rastgele örneklemede normal dağılım tercih edilmiştir.

C. Altyazıların Hazırlanması

Klipler elde edildikten sonra içerisindeki hareketlerin metin olarak elde edilmesi için UniVL altyazılama modeli kullanılmıştır. UniVL [1] bir metin-video ortak modelidir. Metin ve görsel girdiyi kodlamak için iki ayrı Transformer [18] modeli kullanılmaktadır ve bu iki akışı birleştirmek için farklı bir Transformer modelinden daha yararlanılmaktadır. Sonrasında bir decoder yardımı ile altyazılar üretilmektedir. 5 farklı amaç fonksiyonu ile ana model eğitilmekte ve sonrasında 4 farklı alt görev için ince ayar yapılmaktadır. Bu görevlerden birisi de altyazılama görevidir. UniVL modeli How2 [2] veri kümesi üzerinde eğitildiği için altyazı formatı YouCook2 ile farklıdır. Bu yüzden model altyazılama için YouCook2 eğitim kümesi üzerinde eğitilmiştir.

D. VideoCLIP Metin-Video Ortak Modeli

Çalışmamızda metin-video bul-getir görevinde YouCook2 üzerindeki en güncel duyarlılık sonuçlarından birine sahip olan VideoCLIP [15] modeli kullanılmıştır. VideoCLIP modeli görsel ve metinsel girdileri ayrı ön-eğitilmiş modeller ile kodladıktan sonra iki ayrı çok katmanlı algılayıcı ile bu öznitelikleri önceden tanımlı bir boyuta yansıtmaktadır.

$$x_v = f_{MLP-v}(f_{CNN}(c_v)) \quad (1)$$

c_v klip çerçeveleridir ve ön-eğitilmiş S3D modeli f_{CNN} klip çerçevesi ile beslenmektedir. Paralel olarak altyazılar c_t ön-eğitilmiş BERT modeli f_{BERT} sayesinde metinsel token'lara dönüştürülmektedir. Buradaki f_{CNN} ve f_{text} modellerinin ağırlıkları eğitim sırasında dondurulmuştur. Sonrasında çıkartılan görsel ve metinsel token'lar f_{MLP-v} ve f_{MLP-t} modelleri tarafından 512 boyuta yansıtılmaktadır. Sonrasında elde edilen token'lar bir Transformer modeli ile kodlanmakta ve gizli durumlar elde edilmektedir.

$$h_v = f_{gorsel}(x_v), h_t = f_{metinsel}(c_t) \quad (2)$$

İki ayrı Transformer modeli ile elde edilen görsel ve metinsel gizli durumlar h_v ve h_t ortalama havuzlama ile tekil birer öznitelik vektörüne dönüştürülmektedir.

$$z_v = OrtHavuzlama(h_v), z_t = OrtHavuzlama(h_t) \quad (3)$$

Modeli optimize etmek için karşıtsal amaç fonksiyonu olan InfoNCE [19] kullanılmıştır. Karşıtsal amaç fonksiyonlarında pozitif ve negatif örneklerin seçimi kritik önem taşımaktadır. Kliplerde geçici olarak örtüşen kısımlar alınarak zorlu negatif seçim yapılmıştır.

V. DENEYSEL SONUÇLAR VE ANALİZ

VideCLIP eğitimleri Tesla V100 grafik kartı üzerinde yapılmıştır. Eğitim senaryosu aynı tutulmuş, iyileştirici olarak Adam kullanılmıştır. Öğrenme oranı 5.0e-06 ve ağırlık kaybı 0.9 olarak ayarlanmıştır. Eğitimdeki toptan sayısı 128, ve dönem sayısı 10 olarak ayarlanmıştır.

Temel eğitimi yapmak için erişilen YouCook2 eğitim videoları ile eğitim tekrarlanmış ve YouCook2 doğrulama kümesi

¹<https://github.com/alexmercerind/youtube-search-python>

TABLEO II: VIDEOCLIP EĞİTİM SONUÇLARI

Eğitim Kümesi	Test Kümesi	R@1↑	R@5↑	R@10↑
YC2-eğitim	YC2-doğrulama	33.27	63.14	76.17
YC2-eğitim + HuCook	YC2-doğrulama	34.21	64.59	75.92

üzerindeki sonuçlar raporlanmıştır. Sonrasında toplanan verinin YouCook2 ile uyumlu olup olmadığını kontrol etmek adına YouCook2 üzerinde eğitilmiş VideoCLIP modeli yeni veri üzerinde çalıştırılmış ve duyarlılık sonucu raporlanmıştır. Son olarak toplanan HUCook verisi ile YouCook2 eğitim kümesi birleştirilip doğrulama kümesi üzerinde sonuç alınmıştır. İlgili duyarlılık sonuçları Tablo II’de verilmiştir. Bul-getir probleminde arama uzayının büyüklüğü duyarlılık metriğini etkilediği için HUCook verisinden rastgele YouCook2 doğrulama kümesi büyüklüğüne yakın sayıda örnek seçilmiştir. Bu seçilen 3000 tane örnek üzerinde sadece YouCook2 eğitim kümesi üzerinde eğitilmiş VideoCLIP ile 23.40% duyarlılık alınmıştır.

Deneylerin sonuçlarına göre yeniden gerçekleştirilen YouCook2 eğitim kümesi üzerindeki VideoCLIP eğitiminde 33.27% duyarlılık oranı elde edilmiştir. Otomatik olarak indirilen, klipleri çıkarılan ve altyazılanan veri eklendiğinde ise duyarlılık oranı 34.21% oranına çıkmıştır. Top10 duyarlılık sonuçlarında duyarlılık oranı düştüğü gözlemlenmiştir. Nitekim olarak sonuçları incelediğimizde kliplerdeki hareketler doğru olsa bile içerdiği nesnelerin farklı olduğu durumlardaki yanlışların genişletilmiş veri ile eğitilen modelde düzeldiği tespit edilmiştir. Şekil 3’de görüldüğü gibi yaymak, yerleştirmek ve eklemek gibi fiiller yanlış getirilen örneklerde olsa bile içerisindeki nesneler yanlış getirilmiştir. Genişletilen veri ile eğitilen modelin bu konuda daha gürbüz olduğu gözlemlenmiştir.

VI. SONUÇ

Bu çalışmamızda yemek pişirme alanına özel bir veri kümesi olan YouCook2 setini otomatik olarak genişletmek için bir akış önerilmiştir. Bu akış kullanılarak veri kümesine özel anahtar kelimeler ile Youtube üzerinden ilgili videolar bulunmuştur. Bu videolardan otomatik olarak klipler çıkartılmış ve bu kliplerle uyumlu hareket etiketleri otomatik olarak hazırlanmıştır. Sonrasında bu metin-video çiftleri YouCook2 veri kümesine eklenmiş ve otomatik olarak artırılan verinin önceden belirlenen metin-video ortak modeli eğitiminde daha iyi sonuçlar verdiği gözlemlenmiştir. Top1 duyarlılık 33.27% oranından 34.21% oranına çıkartılmıştır.

TEŞEKKÜR

Bu çalışma 118E283 NO’lu TÜBİTAK projesi kapsamında desteklenmiştir.

KAYNAKLAR

- [1] H. Luo, L. Ji, B. Shi, H. Huang, N. Duan, T. Li, J. Li, T. Bharti, and M. Zhou, “Univl: A unified video and language pre-training model for multimodal understanding and generation,” *arXiv preprint arXiv:2002.06353*, 2020.
- [2] A. Miech, D. Zhukov, J. Alayrac, M. Tapaswi, I. Laptev, and J. Sivic, “Howto100m: Learning a text-video embedding by watching hundred million narrated video clips,” *CoRR*, vol. abs/1906.03327, 2019.
- [3] L. Zhou, C. Xu, and J. Corso, “Towards automatic learning of procedures from web instructional videos,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.



Şekil 3: Verilen bir sorgu cümlesi üzerine sadece YouCook2 ve artırılmış veri ile eğitilen modellerin getirdiği videolardan çerçeveler gösterilmiştir. Kırmızı çerçeveler yanlış, yeşil çerçeveler doğru getirilen videoları temsil etmektedir.

- [4] G. A. Sigurdsson, G. Varol, X. Wang, A. Farhadi, I. Laptev, and A. Gupta, “Hollywood in homes: Crowdsourcing data collection for activity understanding,” in *Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14*. Springer, 2016, pp. 510–526.
- [5] M. Bain, A. Nagrani, G. Varol, and A. Zisserman, “Frozen in time: A joint video and image encoder for end-to-end retrieval,” in *IEEE International Conference on Computer Vision*, 2021.
- [6] H. Kuehne, A. B. Arslan, and T. Serre, “The language of actions: Recovering the syntax and semantics of goal-directed human activities,” in *Proceedings of Computer Vision and Pattern Recognition Conference (CVPR)*, 2014.
- [7] D. Damen, H. Doughty, G. M. Farinella, S. Fidler, A. Furnari, E. Kazakos, D. Moltisanti, J. Munro, T. Perrett, W. Price, and M. Wray, “Scaling egocentric vision: The epic-kitchens dataset,” in *European Conference on Computer Vision (ECCV)*, 2018.
- [8] D. Damen, H. Doughty, G. M. Farinella, A. Furnari, J. Ma, E. Kazakos, D. Moltisanti, J. Munro, T. Perrett, W. Price, and M. Wray, “Rescaling egocentric vision: Collection, pipeline and challenges for epic-kitchens-100,” *International Journal of Computer Vision (IJCV)*, vol. 130, p. 33–55, 2022.
- [9] C. Sun, A. Myers, C. Vondrick, K. Murphy, and C. Schmid, “Videobert: A joint model for video and language representation learning,” in *Proceedings of the IEEE/CVF international conference on computer vision*, 2019, pp. 7464–7473.
- [10] S. Xie, C. Sun, J. Huang, Z. Tu, and K. Murphy, “Rethinking spatiotemporal feature learning for video understanding,” *arXiv preprint arXiv:1712.04851*, vol. 1, no. 2, p. 5, 2017.
- [11] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “Bert: Pre-training of deep bidirectional transformers for language understanding,” *arXiv preprint arXiv:1810.04805*, 2018.
- [12] A. Miech, J.-B. Alayrac, L. Smaira, I. Laptev, J. Sivic, and A. Zisserman, “End-to-end learning of visual representations from uncurated instructional videos,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020, pp. 9879–9889.
- [13] T. Mikolov, K. Chen, G. Corrado, and J. Dean, “Efficient estimation of word representations in vector space,” *arXiv preprint arXiv:1301.3781*, 2013.
- [14] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark *et al.*, “Learning transferable visual models from natural language supervision,” in *International conference on machine learning*. PMLR, 2021, pp. 8748–8763.
- [15] H. Xu, G. Ghosh, P.-Y. Huang, D. Okhonko, A. Aghajanyan, F. Metze, L. Zettlemoyer, and C. Feichtenhofer, “Videoclip: Contrastive pre-training for zero-shot video-text understanding,” *arXiv preprint arXiv:2109.14084*, 2021.
- [16] Y. Ma, G. Xu, X. Sun, M. Yan, J. Zhang, and R. Ji, “X-clip: End-to-end multi-grained contrastive learning for video-text retrieval,” in *Proceedings of the 30th ACM International Conference on Multimedia*, 2022, pp. 638–647.
- [17] S. K. Gorti, N. Vouitsis, J. Ma, K. Golestan, M. Volkovs, A. Garg, and G. Yu, “X-pool: Cross-modal language-video attention for text-video retrieval,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 5006–5015.
- [18] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” *Advances in neural information processing systems*, vol. 30, 2017.
- [19] A. v. d. Oord, Y. Li, and O. Vinyals, “Representation learning with contrastive predictive coding,” *arXiv preprint arXiv:1807.03748*, 2018.